

淘宝MySQL十大经典案例

阿里集团-淘宝网DBA @杨德华Devin 2012-09

Data TCon



个人简介

- 负责淘宝用户中心从IOE迁移到MySQL集群的性能测试,高可用运维,DB可用率达到100%
- 管理数据魔方,SNS,淘宝评价,webww,notify等MySQL集群
- 服务器优化,成本节省,把某个业务线的MySQL机器数量从 100台减少到70台。
- SAS->SSD/FIO的MySQL服务器升级过程
- 负责MySQL5.1.45->5.1.48-> Percona 5.5.18的工作



淘宝线上十大MySQL经典案例

- 数据库设计相关:
 - (一) InnoDB表如何设计主键索引
- SQL相关:
 - (二)字符串索引隐式转换
 - (三) 表数据被莫名清空
 - (四) InnoDB表更新锁问题
- 客户端相关:
 - (五)客户端连接被中断



淘宝线上十大MySQL经典案例

- "灵异事件"相关:
 - (六)核心数据库被同时关闭
- Slave相关:
 - (七) Slave 事件Loop
 - (八) Slave 更新操作找不到对应记录
 - (九)备库设置read_only被堵塞
- Swap相关:
 - (十) 数据库服务器Swap



```
CREATE TABLE `a` (
'id' bigint(20) NOT NULL AUTO_INCREMENT,
`message_id` int(11) NOT NULL,
`user_id` int(11) NOT NULL,
'msg' varchar(1024) DEFAULT NULL,
`gmt_create` datetime NOT NULL,
PRIMARY KEY ('id'),
KEY `user_id` (`user_id`, `message_id`),
KEY `idx_gmt_create` (`gmt_create`)
) ENGINE=InnoDB DEFAULT CHARSET=gbk;
```

```
CREATE TABLE `b` (
  `user_id` int(11) NOT NULL,
  `message_id` int(11) NOT NULL,
  `msg` varchar(1024) DEFAULT NULL,
  `gmt_create` datetime NOT NULL,
  PRIMARY KEY (`user_id`,`message_id`),
  KEY `idx_gmt_create` (`gmt_create`)
  ) ENGINE=InnoDB DEFAULT CHARSET=gbk;
```



```
CREATE TABLE `a` (
'id' bigint(20) NOT NULL AUTO_INCREMENT,
`message_id` int(11) NOT NULL,
`user_id` int(11) NOT NULL,
'msg' varchar(1024) DEFAULT NULL,
`gmt_create` datetime NOT NULL,
PRIMARY KEY ('id'),
KEY `user_id` (`user_id`, `message_id`),
KEY `idx_gmt_create` (`gmt_create`)
) ENGINE=InnoDB DEFAULT CHARSET=gbk;
```

```
CREATE TABLE `b` (
  `user_id` int(11) NOT NULL,
  `message_id` int(11) NOT NULL,
  `msg` varchar(1024) DEFAULT NULL,
  `gmt_create` datetime NOT NULL,
  PRIMARY KEY (`user_id`,`message_id`),
  KEY `idx_gmt_create` (`gmt_create`)
) ENGINE=InnoDB DEFAULT CHARSET=gbk;
```

大多数互联网业务(用户,消息),都可以 选择a或者b来满足业务需求,但a表和b表有何区别?



ľ				优点) / / / / / / / / / / / / / / / / / / /	缺点
	A表	500万(顺序)	509M	主键ID自增,在写入数据的时候,Btree分裂成本低,写性能高	?
	B表	500万 (随机)	361M	?	?



ľ		记录	空间	优点	缺点
(A表	500万(顺序)	509M	主键ID自增,在写入数据的时候,Btree分裂成本低,写性能高	?
	B表	500万 (随机)	361M	1.物理空间相对减少 2.根据user_id查数据,直 接走主键拿到数据,无 需回表	?



ľ		记录	空间	优点	缺点
	A表	500万	509M	主键ID自增,在写入数据的时候,Btree分裂成本低,写性能高	物理空间相对较多如果根据user_id来查记录,需要走两次IO
	B表	500万	361M	1.物理空间相对减少 2.根据user_id查数据, 直接走主键拿到数据, 无需回表	?



(记录	空间	优点	缺点
	A表	500万	509M	主键ID自增,在写入数据的时候,Btree分裂成本低,写性能高	物理空间相对较多如果根据user_id来查记录,需要走两次IO
	B表	500万	361M	1.物理空间相对减少 2.根据user_id查数据, 直接走主键拿到数据, 无需回表	(user_id,message_id) 为随机写入,Btree分 裂成本高,写性能低



.1 LST	isternie wer in and control						
	优点	适用 场景?					
A表	主键ID自增,在写入数据的时候,Btree分裂成本低,写性能高	写操作较多的场景					
B表	1.物理空间相对减少 2.根据user_id查数据,直接走 主键拿到数据,无需回表						



1115	= WeW COUNTY	
	优点	适用 场景?
A表	主键ID自增,在写入数据的时候,Btree分裂成本低,写性能高	写操作较多的场景
B表	1.物理空间相对减少 2.根据user_id查数据,直接走 主键拿到数据,无需回表	写少读多的场景,例如从hadoop回流到MySQL的统计结果表,这种统计结果一般数据较多,但主要是读



```
Create Table: CREATE TABLE 'index str' (
 'id' int(11) NOT NULL AUTO INCREMENT,
 `user id` varchar(30) NOT NULL,
 `name` varchar(30) DEFAULT NULL,
 PRIMARY KEY ('id'),
 KEY 'idx user id' ('user id')
) ENGINE=InnoDB AUTO INCREMENT=4 DEFAULT
CHARSET=gbk
```



```
Create Table: CREATE TABLE 'index str' (
 'id' int(11) NOT NULL AUTO INCREMENT,
`user_id` varchar(30) NOT NULL,
                                   Id一般为数字,但这个
                                  表把id定义为了varchar
 `name` varchar(30) DEFAULT NULL,
                                  类型。
 PRIMARY KEY ('id'),
 KEY 'idx user id' ('user id')
) ENGINE=InnoDB AUTO INCREMENT=4 DEFAULT
CHARSET=gbk
```



```
root@test 11:39:38>select * from index_str;
     user id | name |
  1 | 1111 | NULL |
 2 | 0001 | NULŁ
3 rows in set (0.00 sec)
```

恩...有三条记录



id: 1

select type: SIMPLE

table: index str

type: ALL

possible keys: idx user id

key: NULL

key len: NULL

ref: NULL

rows: 3

Extra: Using where

1 row in set (0.00 sec)

当user_id=1的时候,查询分析器表

示没用到idx_user_id索引

```
root@test 11:50:32>explain select * from index str where user id='1'\G
id: 1
 select type: SIMPLE
      table: index_str
       type: ref
possible keys: idx user id
       key: idx user id←
    key len: 62
       ref: const
       rows: 1
      Extra: Using where
1 row in set (0.00 sec)
```

当user id='1'的时候,查询分析器用到 了idx user id的索引

SQL相关案例二字符串索引隐式转换 原因分析

• 数字类型的0001等价于1

• 字符串的0001和1不等值

· 当字符串的列有对应的索引,而在where条件里面不指定为字符串,index无法确认最终的记录

```
root@test 11:58:42> select * from index_str where user_id 70001\G
************************** 1. row *******************
   id: 2
                               user id=0001的时候,MySQL返
user id: 0001
                               回两条记录(被转换成1)
  name: NULL
********
                            *********
   id: 3
user_id: 1
  name: NULL
2 rows in set (0.00 sec)
root@test 11:58:48> select * from index_str where user_id='9001' \G
id: 2
                                 user id='0001'的时候,MySQL
user id: 0001
                                 返回一条记录
  name: NULL
1 row in set (0.00 sec)
```

```
root@test 11:59:03> select * from index str where user id=1\G
id: 2
                              user id=1的时候,MySQL返回
user id: 0001⊱
                               两条记录(被转换成数字值)
  name: NULL
                             **********
   id: 3
user id: 1≤
  name: NULL
2 rows in set (0.00 sec)
root@test 11:59:21> select * from index_str where user_id='1' \G
************************** 1. row ********************
   id: 3
                                    user_id='1'的时候,MySQL
user id: 1
                                    返回两条记录
  name: NULL
1 row in set (0.00 sec)
```

• 被隐式转换后,会进行全表遍历

• 建表需要注意对应好字段类型



- root@test 12:34:22>select * from test_delete;
- t-t--+
- e (sw-lid
- 1 cr + ----+
- | 551
- | 2 |
- | 3 |
- | 4|
- | 5 |
- +----+
- 5 rows in set (0.00 sec)

全表清理的普通写法

- 1. delete from test_delete;
- 2.delete from test_delete
 where id in(1,2,3,4,5);
- 3.truncate table test_delete;
- 4. delete from test_delete where id >0;
- 还有什么二逼语句可以删除全表数据?

delete from test_delete where 'a'='a';
 Query OK, 5 rows affected (0.00 sec)

2.delete from test_delete where id=1 or 'a'='a'; Query OK, 5 rows affected (0.00 sec)

3. delete from test_delete where id; Query OK, 5 rows affected (0.00 sec)



DELETE FROM test_delete
WHERE EXISTS (SELECT *
FROM (SELECT *
FROM test_delete
WHERE id = 5) AS b);
Query OK, 5 rows affected (0.00 sec)



DELETE FROM test_delete
WHERE EXISTS (SELECT *
FROM (SELECT *
FROM test_delete
WHERE id = 5) AS b);

Query OK, 5 rows affected (0.00 sec)

exists后面的子查询是有返回值,恒真. 导致前面的delete语句被触发



SQL相关案例四 InnoDB表更新锁问题

```
CREATE TABLE `a` (

`id` bigint(20) NOT NULL AUTO_INCREMENT,

`message_id` int(11) NOT NULL,

`user_id` int(11) NOT NULL,

'msg` varchar(1024) DEFAULT NULL,

`gmt_create` datetime NOT NULL,

PRIMARY KEY (`id`),

KEY `user_id` (`user_id`,`message_id`),

KEY `idx_gmt_create` (`gmt_create`)
```

) ENGINE=InnoDB DEFAULT CHARSET=gbk;

```
UPDATE message_auto
SET gmt_create = Now()
WHERE msg IS NOT NULL;
```

tx isolation=REPEATABLE-READ

业务需要订正数据

msg is not null 用不到索引,也没有索引 对于其他insert,delete,update,select会有何影响?



```
root@test 01:21:21>update message_auto set gmt_create=now() where mtext is not null;
```

Query OK, 5000002 rows affected (1 min 21.88 sec) Rows matched: 5000002 Changed: 5000002 Warnings: 0

root@test 01:21:23>update message_auto set gmt_create=now() where id=1;

Query OK, 1 row affected (1 min 16.96 sec) Rows matched: 1 Changed: 1 Warnings: 0

root@test 01:22:08>insert into message_auto value(10000001,1,1,'hello','hello',now());

Query OK, 1 row affected (0.00 sec)

root@test 01:22:12>update message_auto set gmt_create=now() where id=10000001;

Query OK, 1 row affected (0.01 sec) Rows matched: 1 Changed: 1 Warnings: 0



```
root@test 01:21:21>update message_auto set gmt_create=now() where mtext is not null;
```

Query OK, 5000002 rows affected (1 min 21.88 sec) Rows matched: 5000002 Changed: 5000002 Warnings: 0

```
root@test 01:21:23>update message_auto set
gmt_create=now() where id=1;
```

Query OK, 1 row affected (1 min 16.96 sec) Rows matched: 1 Changed: 1 Warnings: 0

id=1的记录update操作需要和update全表差不多的时间

root@test 01:22:08>insert into message_auto
value(10000001,1,1,'hello','hello',now());

Query OK, 1 row affected (0.00 sec)

root@test 01:22:12>update message_auto set gmt_create=now() where id=10000001;

Query OK, 1 row affected (0.01 sec) Rows matched: 1 Changed: 1 Warnings: 0

insert新的记录和update最新的记录,时间非常短



SQL相关案例四 InnoDB表更新锁问题

show engine innodb status\G

```
mysql tables in use 1, locked 1
```

649 lock struct(s), heap size 80312, 146316 row lock(s), undo log entries 145669

MySQL thread id 2675649, query id 610234950 localhost root Updating

update message_auto set gmt_create=now() where mtext is not null



PHP Warning: mysql_connect() [function.mysql-connect'>function.mysql-connect): Can't connect to MySQL server on '客户端IP地址' (99) in /home/admin/cai/html/common/db_mysql.clas s.php on line 27



PHP Warning: mysql_connect() [function.mysql-connect'>function.mysql-connect]: Can't connect to MySQL server on '客户端IP地址' (99) in /home/admin/cai/html/common/db_mysql.class.php on line 27

perror 99

OS error code 99: Cannot assign requested address



• 客户端的TCP连接相关统计信息

80端口连接数(CurrentConnection): 16

nginx进程数量: 10

php进程数量: 130

TCP连接状态:

TIME_WAIT 26258

FIN_WAIT1 1

FIN_WAIT2 6

ESTABLISHED 893

TIME_WAIT的数量非常多,也可

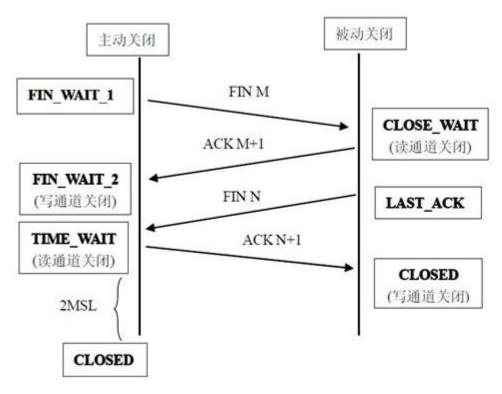
以通过netstat –ant | grep

TIME WAIT来排查



- TIME_WAIT过多的原因
- nginx使用了短连接方式,会造成大量处于 TIME_WAIT状态的连接





- 解决办法
 - 让TIME_WAIT状态可以重用,这样即使 TIME_WAIT占满了所有端口,也不会拒绝新的 请求造成障碍

```
net.ipv4.tcp_tw_recycle = 1
```

net.ipv4.tcp_tw_reuse = 1 让TIME_WAIT尽快回 收



其他案例

Cause: org.jboss.util.NestedSQLException: No ManagedConnections available within configured blocking timeout (1000 [ms]); - nested throwable: (javax.resource.ResourceException: No ManagedConnections available within configured blocking timeout (1000 [ms]))

Java服务器频繁GC导致没有可用连接池



其他案例

2011-02-23 11:47:16 WARNING
 CONNECT_ERROR {"host":"172.19.70.59","port":3306,"user":"USE R","pass":"3*******2","error":"Can't connect to MySQL server on '客户端IP' (4)"}

错误代码4是表示系统中断 PHP服务器文件句柄不足,连接被中断



昨天下午14点44分

两台核心MySQL数据库在同时升级一个任务调度程序

120921 14:44:54 [Note] /u01/mysql/libexec/mysqld:

Normal shutdown

A服务器

120921 14:44:54 [Note] /u01/mysql/libexec/mysqld: Normal shutdown

B服务器



120921 14:44:54 [Note] /u01/mysql/libexec/mysqld:

Normal shutdown

共同点都是同一个时间点开始 Normal shutdown

120921 14:44:54 [Note] /u01/mysql/libexec/mysqld: Normal shutdown

Kill -9 mysqld_pid mysqld_safe Number of processes running now: 0 mysqld_safe mysqld restarted

可以让MySQL Normal Shutdown的命令 本地执行

mysqladmin –uroot –pxxx shutdown mysqladmin –uroot –pxxx sh

超级用户远程shutdown mysqladmin –utest –pxxx –hxxxx shutdown

单时候开着电脑的DBA不多,除了并发更新监控程序,再没有其他操作。调度程序里面也没有进行shutdown的操作



可以让MySQL Normal Shutdown的命令 本地执行

mysqladmin –uroot –pxxx shutdown mysqladmin –uroot –pxxx sh

超级用户远程shutdown mysqladmin –utest –pxxx –hxxxx shutdown

当时候开着电脑的DBA不多,除了并发更新监控程序,再没有其他操作。监控程序里面也没有带有shutdown的操作



kill -9 mysqld_pid 和kill mysqld_pid的区别?

Kill -9 mysqld_pid mysqld_safe Number of processes running now: 0 mysqld_safe mysqld restarted

kill -9 mysqld_pid 和kill mysqld_pid的区别?

kill mysqld_pid

InnoDB: Normal Shutdown...



调度程序(agent)的启动和重启

启动agent的同时,把自己的pid记录到一个文件

重启agent的时候,获取文件里面的pid,调用os.kill(pid)杀掉agent进程



相关事件回放

9.13之前:agent和MySQL都存活,假设pid分别为a,m

9.13:机器硬件维护,MySQL正常关闭,机器重启,agent被异常关闭,但记录pid的文件没被删除

9.13: MySQL重新启动,OS分配了pid(a)给MySQL, 但agent没被启动



相关事件回放

9.21(昨天) 升级agent程序,先将agent关闭,agent里面的代码直接执行了os.kill(a)

由于a这个pid已经是属于MySQL的pid, 当agent执行os.kill(a)的时候 MySQL日志打印Normal shutdown



总结

os.kill(pid)得判断这个pid是否属于自己,避免误杀

OS的pid分配,可能会分配其他已被关闭程序的pid

内核版本 2.6.18-164.el5

/proc/sys/kernel/pid_max 32768([signed] short int)



Seconds_Behind_Master的定义 每一个Binlog事件,都存了当前事件的时间戳

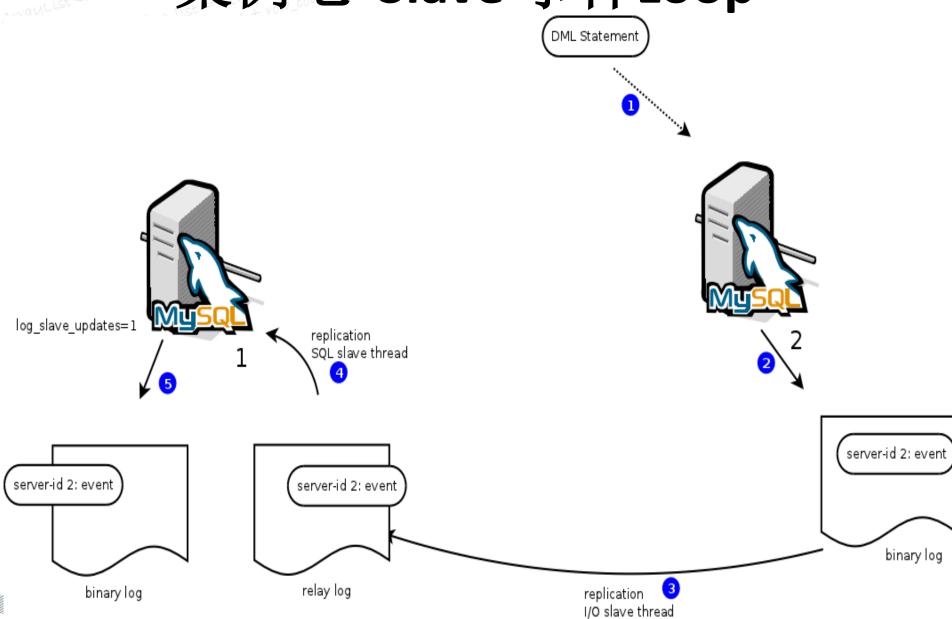
IO_Thread执行当前事件的时间戳 (A)

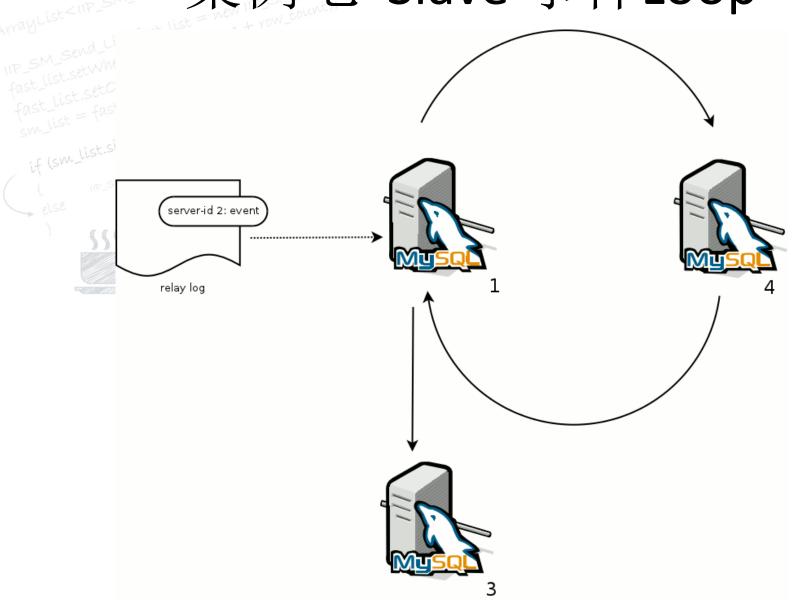


SQL_Thread执行当前事件的时间戳 (B)

Seconds_Behind_Master=A-B







- 简单重现的办法
- 1.配置server1和server2为双主结构:
 server1(server_id=1) <-(MM)-> server2(server_id=1)
- 2、在server1执行以下SQL命令:
 - mysql> create table test.t1(id int);
- mysql> stop slave; insert into t1 values(1);
- mysql> set global server id=3;
- mysql> start slave;
- 3、在server1,server2上执行:
 mysql> select count(*) from t1;



- 解决办法
- Change Master toIGNORE_SERVER_IDS

- · 停掉主库的写,在备库寻找最后一个正确的 position, change master to
- 如果修改过server_id,把server_id重新改回来

• 更详细信息 Taobaodba.com MySQL复制事件 在主备之间来回传输检测



案例八 Slave 找不到对应记录

[ERROR] Slave SQL: Could not execute Update_rows event on table tbtry.try_audit; Can't find record in 'xxx_table', Error_code: 1032; handler error HA_ERR_KEY_NOT_FOUND; the event's master log mysql-bin.002403, end_log_pos 67019815, Error_code: 1032



案例八 Slave 找不到对应记录

[ERROR] Slave SQL: Could not execute Update_rows event on table tbtry.try_audit; Can't find record in 'xxx_table', Error_code: 1032; handler error HA_ERR_KEY_NOT_FOUND; the event's master log mysql-bin.002403, end_log_pos 67019815, Error_code: 1032

binlog_format='ROW',binlog里面记录每个字段的具体值, 通过slave error handler进行检测回补



案例八 Slave 找不到对应记录



案例九备库设置read_only被堵塞

ld: 328071

User: root

Host: localhost

db: NULL

Command: Query

Time: 81

State: Waiting for table flush

Info: set global read_only=1

Rows_sent: 0

Rows_examined: 0

Rows_read: 1



案例九备库设置read_only被堵塞

ld: 328071

User: root

Host: localhost

db: NULL

Command: Query

Time: 81

State: Waiting for table flush

Info: set global read_only=1

Rows_sent: 0

Rows_examined: 0

Rows_read: 1

备库正在执行mysqldump

十线上数据库出现swap的案例

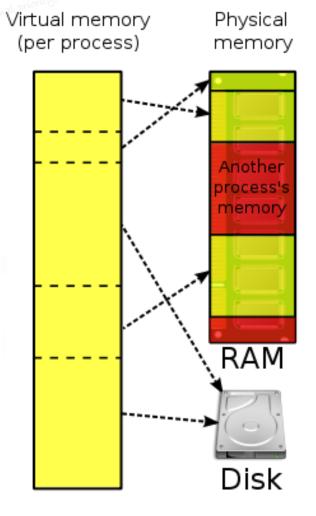
- 前端请求响应变慢
- DB 负载上升
- free -m 后发现 开始使用Swap

\$free -m		oqui omi				
Mem:	total 7800	used 7727 /	free 72	shared 0	buffers 277	cached 2209
	ers/cache: 8189	5240 84	2559 8104			



十线上数据库出现swap的案例

操作系统设置swap的目的



Total Virtual Memory







Swap

^	L1 cache reference	0.5	ns
	Branch mispredict	5	ns
	L2 cache reference	7	ns
	Mutex lock/unlock	25	ns
	Main memory reference	100	ns
/	Compress 1K bytes with Zippy	3,000	ns
	Send 2K bytes over 1 Gbps network	20,000	ns
	Read 1 MB sequentially from memory	250,000	ns
	Round trip within same datacenter	500,000	ns
	Disk seek	10,000,000	ns
	Read 1 MB sequentially from disk	20,000,000	ns
	Send packet CA->Netherlands->CA	150,000,000	ns

- http://www.linux-mag.com/id/7589/
- http://www.cs.cornell.edu/projects/ladis2009/talks/de an-keynote-ladis2009.pdf



十线上数据库出现swap的案例

- Flashcache压测,Flashcache元数据本身需要 内存
- 多实例的主备库混搭
 - mysqldump –q (Don't buffer query, dump directly to stdout)
- /proc/sys/vm/swappiness和/etc/sysctl.conf不 一致
- table_open_cache 和table_definition_cache过 大



ean is empty = false; ArrayList < IIP_SM_Send_List > sm_List; ArrayList setWhere ('rownum < = * + row_count); fast_list_setWhere ('rownum < = * + row_count); fast_list_setOrderBy (*IIP_ID*); fast_list_setOrderBy (*IIP_ID*); fast_list_setOrderBy (*IIP_ID*); fmst_list_setCorderBy (IIP_SM_Send_List); if (sm_list_size() > 0) if (sm_list_setWhere('rownum < = * + row_count); else vormal_list_setWhere('rownum < = * + row_count); vormal_list_setWhere('rownum < = * + row_count); vormal_list_setOrderBy('rownum < = * + row_count)

• 新浪微博@杨德华Devin